

Zadanie 1

Mamy obecnie 10 TB danych. Co miesiąc dochodzi 200 GB, więc po roku będzie około 12,4 TB danych. Do stworzenia i utrzymania Lakehouse w Azure potrzebujesz kilku podstawowych usług:

- Storage – tu trzymamy dane
- Databricks – gdzie przetwarzasz dane. Najdroższy element.
- Key Vault – do bezpiecznego przechowywania haseł i połączeń.
- Data Factory – do automatyzacji zadań, ładowania i przetwarzania danych.
- SQL Server (Azure SQL) – do przechowywania metadanych lub gotowych tabel.

Przy tej skali koszt utrzymania wszystkiego przez rok to około 30 tysięcy.

Zadanie 2

Delta Lake:

1. Dobrze działa w Azure i w Databricks.
2. Szybka, łatwa w obsłudze.
3. Idealna, jeśli chcemy mieć wszystko w jednym miejscu

Iceberg:

1. Lepsza, jeśli korzystam z różnych narzędzi
2. Bardziej elastyczna.
3. Dobra, jeśli pracujemy w różnych systemach

Jeśli robimy wszystko w Azure i Databricks wybieramy Delta Lake. Iceberg warto rozważyć kiedy mamy mieszane środowisko.

Zadanie 3

Architektura medalionu zakłada, że dane przechodzą przez trzy poziomy przetwarzania – od surowych do oczyszczonych i gotowych do raportowania.

Wady:

1. Jest skomplikowana – trzy poziomy to więcej pracy i konfiguracji.
2. Trzeba kopiować dane – zużywa więcej miejsca.
3. Duże koszty
4. Każdy poziom to nowe ryzyko błędów.
5. Opóźnia dostęp do danych – wszystko trwa dłużej.
6. Błędy trudniej namierzyć – trzeba przeszukiwać wiele warstw.

7. Niepotrzebna przy małych projektach
8. Może prowadzić do chaosu, jeśli schematy się różnią.
9. Często warstwa Bronze nie jest w ogóle wykorzystywana.
10. Więcej rzeczy do monitorowania
11. Słabo działa z machine learningiem
12. Narzędzia BI i tak używają tylko końcowej warstwy.
13. Biznes czeka na dane dłużej
14. Nie opłaca się dla MVP
15. Trzeba osobno zarządzać dostępem do każdej warstwy.
16. Trudno kontrolować wersje danych na każdym poziomie.
17. Nie daje elastyczności
18. Powtarzamy te same transformacje w różnych warstwach.
19. Trudno szybko wprowadzać zmiany
20. Utrudnia streaming